


Система оценки качества моделей детекции логических аномалий


Д. А. Сахаров

Московский физико-технический институт
(национальный исследовательский университет)






Что такое логическая аномалия?



Логические аномалии:
Нарушение правил сборки,
комплектации, расположения

Logical Anomaly Detection with Vision Language Model Generated Questions



(A) Модели, обученные с нуля
(AutoEncoder)

(B) Memory-based модели
(PatchCore)

(C) Reasoning-based системы
(LogicQA)

Цели и задачи работы

Цель: Разработать комплексную систему оценки качества рассуждающих VLM-систем для детекции логических аномалий.

Задачи:

Декомпозировать процесс работы VLM на смысловые этапы.

Разработать и адаптировать метрики для каждого уровня рассуждений.

Верифицировать систему на бенчмарке и выявить проблемы архитектуры оригинального фреймворка.

Фреймворк оценки качества: Уровень 1

Восприятие нормы

$$\text{CLIPScore}_{\text{norm}} = \max \left(0, \frac{\max_{k=1}^K \left(\cos \left(E_{\text{text}}(t_k), E_{\text{image}}(v) \right) \times 100 \right)}{100} \times 2.5 \right) \times 100\%$$

Семантическое сходство описания и картинки

$$\text{CCR} = \frac{1}{N_{\text{images}}} \sum_{i=1}^{N_{\text{images}}} \left(\frac{\sum_{j=1}^C I(\text{fact}_j \in \text{desc}_i)}{C} \right) \times 100\%$$

Constraint Coverage Rate (Полнота описания)

Фреймворк оценки качества: Уровень 2 Анализ атрибутов

$$\text{MACE} = \frac{1}{N_{\text{count}}} \sum_{k=1}^{N_{\text{count}}} |\hat{c}_k - c_{\text{gt},k}|$$

Mean Absolute Count Error (Ошибка подсчета объектов)

$$\text{SRA} = \frac{\text{TP}_{\text{spatial}} + \text{TN}_{\text{spatial}}}{N_{\text{spatial}}} \times 100\%$$

Spatial Relation Accuracy (Точность определения пространственных связей)

Фреймворк оценки качества: Уровень 3

Генерация и фильтрация вопросов

$$C_{\text{subQ}} = \frac{1}{N_{\text{main}}} \sum_{i=1}^{N_{\text{main}}} \max \left(0, 1 - \frac{p_i(1 - p_i)}{0.24} \right) \times 100\%$$

Оценка уверенности модели (дисперсия ответов на 5 перефразированных вопросов)



Нормальный экземпляр



Неправильная комплектация

Результаты экспериментов

Оценка\Класс	Breakfast box	Screw Bag
AUROC	78.30%	66.20%
F1-max	83.30%	73.68%
CLIPScore	84.77%	76.86%
Constraint Coverage Rate	63.33%	44.00%
Mean Absolute Count Error	0.44 objects	0.25 objects
Spatial Relation Accuracy	80.08%	80.56%
Sub-Q Consistency Score	58.33%	84.75%

Восприятие (CLIPScore, CCR): результаты согласуются с бенчмарками *VALOR-EVAL*, *FaithScore*.

Атрибуты (SRA ~80%): Уверенно высокий результат (baselines обычных VLM показывают точность около 50-60%).

Рассуждение (Consistency ~58%): Падение согласованности ответов из-за отбраковки правильных гипотез или галлюцинаций

Заключение

- Разработана многоуровневая система оценки, позволяющая интерпретировать ошибки VLM в задачах обнаружения аномалий.
- Главные выводы по LogicQA:
 - Ошибки вызваны дефицитом полноты первичного восприятия (модель упускает логические правила).
 - Ошибки вызваны высокой неуверенностью (галлюцинациями) на этапе ответов на вопросы, что ломает пайплайн фильтрации.
- Предложенный фреймворк открывает путь к направленному совершенствованию VLM-систем.