

Фреймворк few-shot обнаружения логических аномалий на основе визуально-языковых моделей с иерархической оценкой качества визуальных рассуждений

МОСКОВСКИЙ ФИЗИКО-ТЕХНИЧЕСКИЙ ИНСТИТУТ

Д. А. Сахаров

Научный руководитель: Копылов И.С.

2026

Проблема: логические аномалии

Структурная аномалия

- ▶ Царапина, трещина, загрязнение
- ▶ Локальный дефект пикселей
- ▶ PatchCore, DRAEM $\rightarrow$ AUROC > 0.95

VS

Логическая аномалия ← наша задача

- ▶ Нарушение правил комплектации
- ▶ Каждый пиксель нормален — дефект только в смысле
- ▶ «2 мандарина» вместо «1» $\rightarrow$ все методы слепы

Актуальный подход:

визуально-языковая модель как рассуждающий агент — формирует и проверяет семантические ограничения нормальности

Исходная точка: воспроизведение LogicQA

InternVL2.5-8B · n_shots=3 · монолитный Stage 1 · без CoT

Класс	AUROC	F1-max	TP	FP	FN
breakfast_box	0.589	0.619	90	42	83
juice_bottle	0.537	0.751	127	44	109
pushpins	0.543	0.569	51	29	121
screw_bag	0.484	0.692	73	44	146
splicing_connectors	0.481	0.645	160	106	33
AVG	0.527	0.655	—	—	—

GPT-4o (оригинал):

AVG AUROC $\approx$ 0.876

Baseline InternVL2.5-8B:

AVG AUROC = 0.527

Два корневых дефекта:

- ▶ Монолитное описание галлюцинирует и пропускает компоненты (CCR=63%)
- ▶ Модель отвечает «Yes» без реального анализа — yes-bias (FP=42)

Улучшение А: декомпозированный Stage 1

Проблема

- ▶ Один запрос на всё изображение
- ▶ VLM «галлюцинирует» объекты
- ▶ Упускает редкие компоненты
- ▶ CCR baseline = 63.3%



Решение

- ▶ 5 отдельных запросов по компонентам
- ▶ tangerines / nectarine / cereal mix /
- ▶ banana chips / almonds
- ▶ 5 изображений $\times$ 5 = 25 VLM-вызовов

Результат:

CCR: 63% $\rightarrow$ 100%

MACE: 0.44 $\rightarrow$ 0.24

Почему работает: при фокусированном запросе «опиши только отсек с мандаринами» VLM не может галлюцинировать другие объекты — внимание жёстко ограничено компонентом. Все нормативные ограничения попадают в итоговое описание.

Улучшения пайплайна В – F

В Hedge-filtering · Stage 2

Исключаем утверждения с «sometimes», «may», «appears to» из нормативного определения

→ Устойчивость нормативного определения к случайным наблюдениям

С Count-bypass · Stage 3b

Счётные вопросы («exactly N») не проходят 80%-порог фильтрации на val-изображениях

→ VLM систематически ошибается в счёте → без bypass теряются ключевые вопросы

D Stem-matching · Stage 3b

Лемматизация при парсинге ответа: «almonds»→«almond», «tangerines»→«tangerine»

→ Устраняет грамматические ложные отклонения при поиске Yes/No-токена

Е Sub-Q аугментация ×4 · Stage 3c

Каждый вопрос перефразируется в 4 варианта; финальный ответ — majority vote

→ +0.03–0.05 AUROC; устойчивость к поверхностным лингвистическим вариациям

F min_failures = 2 · Stage 4

Аномалия: ≥ 2 основных вопроса получили «No» (вместо порога = 1)

→ FP: 22 → 12 — отсекаем одиночные галлюцинации при несогласии вопросов

Обоснование выбора метрик

Каждая метрика мотивирована внешней работой — не выбрана произвольно

L1	CLIPScore <i>CLIP ViT-B/32</i>	[Hessel et al., EMNLP 2021] Reference-free метрика семантического сходства текст–изображение; широко принята как стандарт оценки качества описаний
L1	CCR (LLM-as-Judge) <i>MT-Bench · Prometheus-Vision</i>	[Zheng et al., NeurIPS 2023] [Lee et al., ACL 2024] VLM-as-Judge коррелирует с оценками людей лучше, чем text-match метрики; Prometheus-Vision — наивысшая корреляция Пирсона среди open-source
L2	MACE · SRA <i>What's 'up' · VALOR-EVAL</i>	[Kamath et al., EMNLP 2023] [Dou & Peng, ACL 2024] VLM достигают 56% точности на пространственных задачах vs 99% людей; VALOR-EVAL показал: объектных метрик недостаточно, нужны атрибуты и отношения
L1	FaithScore / CCR-atomic <i>FaithScore</i>	[Jing et al., arXiv 2023] Атомарная верификация фактов без эталона коррелирует с оценками людей — обосновывает подход «одно ограничение = один вопрос судьё»
L3	Sub-Q Consistency <i>Uncertainty VLMs · POPE</i>	[Kostumov et al., arXiv 2024] [Li et al., EMNLP 2023] Точность VLM не согласована с неопределённостью; POPE: VLM склонны отвечать «Yes» — majority vote по перефразировкам выявляет нестабильные ответы

Улучшение G: inline Chain-of-Thought (RC4-A)

Без CoT (r23):

Is there exactly 2 tangerines?
Answer: Yes / No

→ модель угадывает на основе статистических ожиданий

RC4-A



C CoT (r25):

Step 1 - Observe:
Describe what you see about tangerines.
Step 2 - Conclude:
Is there exactly 2? Result: Yes / No

+ majority vote no 4 перефразировкам вопроса

FP: 12 → 0

AUROC: 0.782 → 0.852

F1-max: 0.746 → 0.818

Механизм: ложноположительный ответ потребовал бы сформулировать несуществующее нарушение. Step 1 Observe создаёт верифицируемую посылку — модель не может соврать, не описав реального нарушения. Yes-bias (POPE, 2023) полностью устранён.

Прогрессия результатов: baseline → r25

breakfast_box · 50 тестовых изображений (25 good + 25 anomaly)

Запуск	AUROC	F1-max	FP	FN	Ключевое
Baseline (avg 5 cls)	0.527	0.655	—	—	Монолитный, без CoT
r18 (decomposed start)	0.521	0.667	1	23	Декомпозиция (нестабильна)
r21 (NORMALITY fix)	0.500	0.667	0	25	Регрессия промптов
r23 (fixes 3b/3c/4)	0.782	0.746	12	3	Исправление Stage 3b/4
r25 ★ CoT	0.852	0.818	0	10	inline CoT · FP=0

AUROC = 0.852

FP = 0

CCR = 100%

Теперь 8B сравнима с
gpt4o

Иерархическая система оценки L1–L4

Зачем: AUROC не показывает, на каком этапе пайплайна возникает ошибка

L1 Восприятие	CLIPScore = 69.7% · CCR = 100%	Описание семантически верное и полное
L2 Атрибуты	MACE = 0.24 · SRA = 64.3%	Счёт точен · пространственные отношения — системная слабость 8B
L2.5 Фильтрация	Precision = 21% · Recall = 63%	Ограничение Qwen2.5-3B-судьи: не различает перефразировки
L3 Рассуждение	Sub-Q Consistency = 70.5%	Умеренная стабильность — VLM неуверена (Kostumov et al. 2024)
L4 Задача	AUROC = 0.852 · F1-max = 0.818 · FP = 0	Лучший результат достигнут

Заключение

1

AUROC 0.527 → 0.852

open-source модель на одном GPU · без API · воспроизводимо

2

FP = 0 · CCR = 100%

CoT + per-component Stage 1 решают разные проблемы

3

FN = 10 → слабость маленьких моделей

системная слабость VLM-8B (56% vs 99% люди, Kamath 2023)

Следующий шаг: InternVL2.5-38B-AWQ для пространственных аномалий · все 5 классов MVTec
LOCO AD